



**Universidade do Minho**  
Escola de Engenharia  
Licenciatura em Engenharia Informática

## **Aprendizagem e Decisão Inteligentes**

Ano Letivo de 2024/2025

### **Modelos de Aprendizagem e Decisão**

Flávia Alexandra Silva Araújo (A96587)  
Frederico Cunha Afonso (A104001)  
Joshua David Amaral Moreira (A105684)  
Miguel Torres Carvalho (A95485)

19 de maio de 2025

# ADI

## Resumo

O presente trabalho foi realizado no âmbito da Unidade Curricular de Aprendizagem e Decisão Inteligentes. O objetivo deste trabalho é a aplicação de técnicas de aprendizagem automática para a previsão de valores de uma variável alvo. Para tal, foi utilizada a plataforma *KNIME* para a realização de todo o processo de análise de dados, desde a importação do *dataset* até à avaliação dos modelos.

Para a primeira fase deste projeto, foi analisado um *dataset* de empréstimos bancários, onde se pretende prever o estado de um empréstimo - se este foi concedido, está pendente ou foi recusado.

Para a segunda fase, foi analisado um *dataset* escolhido pela equipa de trabalho, que contém dados de vários países ao longo de vários anos, permitindo analisar a relação entre o índice de felicidade e a inflação em diferentes contextos.

Este projeto tem como objetivo aplicar técnicas de *Machine Learning* para prever as variáveis alvo de ambos os *datasets*, utilizando diferentes algoritmos e técnicas de pré-processamento, aplicando os conhecimentos adquiridos ao longo da unidade curricular.

# Índice

|                                                                 |           |
|-----------------------------------------------------------------|-----------|
| <b>1. Dataset Loan</b>                                          | <b>1</b>  |
| 1.1. Dataset . . . . .                                          | 1         |
| 1.2. KNIME Workflow . . . . .                                   | 2         |
| 1.3. Análise Preliminar dos Dados . . . . .                     | 2         |
| 1.3.1. Linear e Rank Correlations . . . . .                     | 3         |
| 1.3.2. Missing Values . . . . .                                 | 5         |
| 1.3.3. Outliers . . . . .                                       | 5         |
| 1.3.4. Statistics . . . . .                                     | 6         |
| 1.3.5. Standard Deviation . . . . .                             | 6         |
| 1.4. Pré-Processamento dos Dados . . . . .                      | 6         |
| 1.5. Análise de Dados Após Pré-Processamento . . . . .          | 7         |
| 1.5.1. Missing Values . . . . .                                 | 8         |
| 1.5.2. Outliers . . . . .                                       | 8         |
| 1.5.3. Statistics . . . . .                                     | 9         |
| 1.5.4. Standard Deviation . . . . .                             | 9         |
| 1.5.5. Linear e Rank Correlations . . . . .                     | 9         |
| 1.6. Modelos . . . . .                                          | 10        |
| 1.6.1. Decision Tree . . . . .                                  | 11        |
| 1.6.2. Linear Regression . . . . .                              | 12        |
| 1.6.3. Logistic Regression . . . . .                            | 12        |
| 1.6.4. Clustering . . . . .                                     | 13        |
| 1.6.5. MLP - Multi-Layer Perceptron . . . . .                   | 13        |
| 1.6.6. Decision Tree com <i>feature selection</i> . . . . .     | 15        |
| 1.6.7. Random Forest . . . . .                                  | 16        |
| 1.7. Análise dos Modelos . . . . .                              | 17        |
| <b>2. World Happiness Index and Inflation Dataset</b>           | <b>19</b> |
| 2.1. Dataset . . . . .                                          | 19        |
| 2.2. KNIME Workflow . . . . .                                   | 20        |
| 2.3. Análise Preliminar dos Dados . . . . .                     | 21        |
| 2.3.1. Data Exploration . . . . .                               | 21        |
| 2.3.2. Standard Deviation . . . . .                             | 22        |
| 2.3.3. Missing Values . . . . .                                 | 23        |
| 2.3.4. Outliers . . . . .                                       | 23        |
| 2.4. Modelos . . . . .                                          | 23        |
| 2.4.1. Random Forest . . . . .                                  | 24        |
| 2.4.2. Polynomial Regression . . . . .                          | 26        |
| 2.4.3. Modelos Múltiplos com <i>Feature Selection</i> . . . . . | 27        |
| 2.4.4. Modelos Múltiplos com <i>Binning</i> . . . . .           | 28        |
| 2.4.5. MLP - Multi-Layer Perceptron . . . . .                   | 30        |
| 2.5. Análise dos Modelos . . . . .                              | 30        |
| <b>3. Conclusão</b>                                             | <b>32</b> |
| <b>A. Apêndices</b>                                             | <b>33</b> |
| A.1. Apêndice A: KNIME - Loan Dataset . . . . .                 | 33        |

|                                                                           |           |
|---------------------------------------------------------------------------|-----------|
| A.2. Apêndice B: <i>KNIME</i> - Happiness and Inflation Dataset . . . . . | 38        |
| <b>Bibliografia</b>                                                       | <b>40</b> |

# Índice de Figuras

|                                                                                                                                  |    |
|----------------------------------------------------------------------------------------------------------------------------------|----|
| 1.1. Estrutura do <i>dataset</i> Loan. . . . .                                                                                   | 2  |
| 1.2. <i>KNIME</i> : Estrutura do <i>workflow</i> desenvolvido para o <i>dataset</i> Loan. . . . .                                | 2  |
| 1.3. <i>KNIME</i> : Nodos de leitura do <i>dataset</i> Loan. . . . .                                                             | 3  |
| 1.4. <i>KNIME</i> : Nodos de exploração do <i>dataset</i> Loan. . . . .                                                          | 3  |
| 1.5. <i>KNIME</i> : Matriz de <i>Linear Correlation</i> do <i>dataset</i> Loan. . . . .                                          | 4  |
| 1.6. <i>KNIME</i> : Matriz de <i>Rank Correlation</i> do <i>dataset</i> Loan. . . . .                                            | 4  |
| 1.7. <i>KNIME</i> : Estatísticas descritivas do <i>dataset</i> Loan. . . . .                                                     | 4  |
| 1.8. <i>KNIME</i> : Distribuição de <i>Missing Values</i> do <i>dataset</i> Loan. . . . .                                        | 5  |
| 1.9. <i>KNIME</i> : Boxplot do <i>dataset</i> Loan. . . . .                                                                      | 5  |
| 1.10. <i>KNIME</i> : Estatísticas do <i>dataset</i> Loan. . . . .                                                                | 6  |
| 1.11. <i>KNIME</i> : Desvio padrão do <i>dataset</i> Loan. . . . .                                                               | 6  |
| 1.12. <i>KNIME</i> : Fluxo de trabalho do pré-processamento do <i>dataset</i> Loan. . . . .                                      | 7  |
| 1.13. <i>KNIME</i> : Distribuição de <i>Missing Values</i> do <i>dataset</i> Loan após pré-processamento. . . . .                | 8  |
| 1.14. <i>KNIME</i> : <i>Boxplot</i> do <i>dataset</i> Loan após pré-processamento. . . . .                                       | 8  |
| 1.15. <i>KNIME</i> : Estatísticas do <i>dataset</i> Loan após pré-processamento. . . . .                                         | 9  |
| 1.16. <i>KNIME</i> : Desvio padrão do <i>dataset</i> Loan após pré-processamento. . . . .                                        | 9  |
| 1.17. <i>KNIME</i> : Matriz de <i>Linear Correlation</i> do <i>dataset</i> Loan após pré-processamento. . . . .                  | 10 |
| 1.18. <i>KNIME</i> : Matriz de <i>Rank Correlation</i> do <i>dataset</i> Loan após pré-processamento. . . . .                    | 10 |
| 1.19. <i>KNIME</i> : Modelos de <i>Machine Learning</i> utilizados no <i>dataset</i> Loan. . . . .                               | 11 |
| 1.20. <i>KNIME</i> : Modelo de <i>Decision Tree</i> do <i>dataset</i> Loan. . . . .                                              | 11 |
| 1.21. <i>KNIME</i> : Modelo de <i>Linear Regression</i> do <i>dataset</i> Loan. . . . .                                          | 12 |
| 1.22. <i>KNIME</i> : Modelo de <i>Logistic Regression</i> do <i>dataset</i> Loan. . . . .                                        | 12 |
| 1.23. <i>KNIME</i> : Modelo de <i>Clustering</i> do <i>dataset</i> Loan. . . . .                                                 | 13 |
| 1.24. <i>KNIME</i> : Modelo de <i>MLP</i> do <i>dataset</i> Loan. . . . .                                                        | 13 |
| 1.25. <i>KNIME</i> : Gráfico de dispersão do <i>dataset</i> Loan na <i>hold-out validation</i> . . . . .                         | 14 |
| 1.26. <i>KNIME</i> : Gráfico de dispersão do <i>dataset</i> Loan na <i>cross validation</i> . . . . .                            | 15 |
| 1.27. <i>KNIME</i> : Modelo de <i>Decision Tree</i> com <i>feature selection</i> do <i>dataset</i> Loan. . . . .                 | 15 |
| 1.28. <i>KNIME</i> : Modelo de <i>Random Forest</i> do <i>dataset</i> Loan. . . . .                                              | 16 |
| 1.29. <i>KNIME</i> : Modelo de <i>Backwards Feature Elimination</i> do <i>dataset</i> Loan. . . . .                              | 16 |
| 1.30. <i>KNIME</i> : Modelo de <i>Forward Feature Elimination</i> do <i>dataset</i> Loan. . . . .                                | 17 |
|                                                                                                                                  |    |
| 2.1. <i>KNIME</i> : Fluxo de trabalho do <i>dataset</i> World Happiness Index and Inflation. . . . .                             | 20 |
| 2.2. <i>KNIME</i> : Matriz de <i>Linear Correlation</i> do <i>dataset</i> World Happiness Index and Inflation. . . . .           | 21 |
| 2.3. <i>KNIME</i> : Matriz de <i>Rank Correlation</i> do <i>dataset</i> World Happiness Index and Inflation. . . . .             | 21 |
| 2.4. <i>KNIME</i> : Estatísticas do <i>dataset</i> World Happiness Index and Inflation - parte 1 . . . . .                       | 21 |
| 2.5. <i>KNIME</i> : Estatísticas do <i>dataset</i> World Happiness Index and Inflation - parte 2 . . . . .                       | 22 |
| 2.6. <i>KNIME</i> : Desvio padrão do <i>dataset</i> World Happiness Index and Inflation. . . . .                                 | 22 |
| 2.7. <i>KNIME</i> : Distribuição de <i>Missing Values</i> do <i>dataset</i> World Happiness Index and Inflation. . . . .         | 23 |
| 2.8. <i>KNIME</i> : <i>Boxplot</i> do <i>dataset</i> World Happiness Index and Inflation. . . . .                                | 23 |
| 2.9. <i>KNIME</i> : Modelos de <i>Machine Learning</i> utilizados no <i>dataset</i> World Happiness Index and Inflation. . . . . | 24 |
| 2.10. <i>KNIME</i> : Modelo de <i>Random Forest</i> do <i>dataset</i> World Happiness Index and Inflation. . . . .               | 24 |
| 2.11. <i>KNIME</i> : Preparação de dados do <i>dataset</i> World Happiness Index and Inflation. . . . .                          | 25 |
| 2.12. <i>KNIME</i> : Resultados do modelo de <i>Random Forest</i> do <i>dataset</i> World Happiness Index and Inflation. . . . . | 25 |

|                                                                                                                                                                  |    |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.13. <i>KNIME</i> : Modelo de <i>Polynomial Regression</i> do dataset World Happiness Index and Inflation.                                                      | 26 |
| 2.14. <i>KNIME</i> : Resultados do modelo de <i>Polynomial Regression</i> do dataset World Happiness Index and Inflation. . . . .                                | 26 |
| 2.15. <i>KNIME</i> : Modelos de <i>Machine Learning</i> múltiplos do dataset World Happiness Index and Inflation. . . . .                                        | 27 |
| 2.16. <i>KNIME</i> : Preparação de dados do modelo de <i>Machine Learning</i> múltiplo do dataset World Happiness Index and Inflation. . . . .                   | 27 |
| 2.17. <i>KNIME</i> : Resultados do modelo de <i>Machine Learning</i> múltiplo do dataset World Happiness Index and Inflation. . . . .                            | 28 |
| 2.18. <i>KNIME</i> : Modelos de <i>Machine Learning</i> múltiplos do dataset World Happiness Index and Inflation - <i>Binning</i> . . . . .                      | 28 |
| 2.19. <i>KNIME</i> : Preparação de dados do modelo de <i>Machine Learning</i> múltiplo do dataset World Happiness Index and Inflation - <i>Binning</i> . . . . . | 29 |
| 2.20. <i>KNIME</i> : Resultados do modelo de <i>Machine Learning</i> múltiplo do dataset World Happiness Index and Inflation - <i>Binning</i> . . . . .          | 29 |
| 2.21. <i>KNIME</i> : Modelo de <i>MLP</i> do dataset World Happiness Index and Inflation. . . . .                                                                | 30 |
| 2.22. <i>KNIME</i> : Resultados do modelo de <i>MLP</i> do dataset World Happiness Index and Inflation.                                                          | 30 |
|                                                                                                                                                                  |    |
| A.1. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Decision Tree</i> com <i>hold-out validation</i> do dataset Loan. . . . .                            | 33 |
| A.2. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Decision Tree</i> com <i>cross validation</i> do dataset Loan.                                       | 33 |
| A.3. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Linear Regression</i> com <i>hold-out validation</i> do dataset Loan. . . . .                        | 34 |
| A.4. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Linear Regression</i> com <i>cross validation</i> do dataset Loan. . . . .                           | 34 |
| A.5. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Logistic Regression</i> com <i>hold-out validation</i> do dataset Loan. . . . .                      | 34 |
| A.6. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Logistic Regression</i> com <i>cross validation</i> do dataset Loan. . . . .                         | 35 |
| A.7. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Clustering</i> com <i>hold-out validation</i> do dataset Loan.                                       | 35 |
| A.8. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Clustering</i> com <i>cross validation</i> do dataset Loan.                                          | 35 |
| A.9. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Decision Tree</i> com <i>feature selection</i> e <i>hold-out validation</i> do dataset Loan. . . . . | 36 |
| A.10. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Decision Tree</i> com <i>feature selection</i> e <i>cross validation</i> do dataset Loan. . . . .   | 36 |
| A.11. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>MLP</i> com <i>hold-out validation</i> do dataset Loan. .                                           | 36 |
| A.12. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>MLP</i> com <i>cross validation</i> do dataset Loan. . .                                            | 37 |
| A.13. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Backwards Feature Selection</i> com <i>hold-out validation</i> do dataset Loan. . . . .             | 37 |
| A.14. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Backwards Feature Selection</i> com <i>cross validation</i> do dataset Loan. . . . .                | 37 |
| A.15. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Forward Feature Selection</i> com <i>hold-out validation</i> do dataset Loan. . . . .               | 38 |
| A.16. <i>KNIME</i> : <i>Confusion Matrix</i> do modelo de <i>Forward Feature Selection</i> com <i>cross validation</i> do dataset Loan. . . . .                  | 38 |
| A.17. <i>KNIME</i> : <i>Scorer</i> do modelo de <i>Random Forest</i> do dataset World Happiness Index and Inflation.                                             | 38 |
| A.18. <i>KNIME</i> : <i>Scorer</i> do modelo de <i>Polynomial Regression</i> do dataset World Happiness Index and Inflation. . . . .                             | 39 |
| A.19. <i>KNIME</i> : <i>Scorer</i> do modelo de <i>Machine Learning</i> múltiplo do dataset World Happiness Index and Inflation. . . . .                         | 39 |
| A.20. <i>KNIME</i> : <i>Scorer</i> do modelo de <i>Machine Learning</i> múltiplo do dataset World Happiness Index and Inflation - <i>Binning</i> . . . . .       | 39 |
| A.21. <i>KNIME</i> : <i>Scorer</i> do modelo de <i>MLP</i> do dataset World Happiness Index and Inflation. . . .                                                 | 39 |

# Índice de Tabelas

|                                                                                         |    |
|-----------------------------------------------------------------------------------------|----|
| 1.1. Resultados dos modelos de <i>Machine Learning</i> do <i>dataset Loan</i> . . . . . | 18 |
| 2.1. Resultados dos modelos de <i>Machine Learning</i> do <i>dataset Loan</i> . . . . . | 31 |

# 1. *Dataset Loan*

## 1.1. *Dataset*

O *dataset* utilizado neste projeto, atribuído de acordo com o número do grupo, foi o *Loan Dataset*, que contém informações sobre empréstimos bancários.

O *dataset* é composto por 3 ficheiros - *loan\_train.csv*, *loan\_test.csv* e *loan\_new\_problems.csv*. Ambos os ficheiros *loan\_train.csv* e *loan\_test.csv* contêm 4001 linhas e 17 colunas, sendo a última coluna a variável alvo. Quanto ao ficheiro *loan\_new\_problems.csv*, este contém 501 linhas e 16 colunas, não contendo a variável alvo. Cada linha destes ficheiros corresponde à informação de um pedido de empréstimo. Por conseguinte, o objetivo deste projeto é prever o estado de um empréstimo, sendo este concedido, pendente ou recusado.

As *features* presentes no *dataset* são as seguintes:

- ***date:*** Data de nascimento do cliente.
- ***person\_name:*** Nome do cliente.
- ***person\_age:*** Idade do cliente.
- ***person\_gender:*** Género do cliente.
- ***person\_education:*** Grau de escolaridade do cliente.
- ***person\_income:*** Rendimento anual do cliente.
- ***person\_emp\_exp:*** Anos de experiência profissional do cliente.
- ***person\_home\_ownership:*** Tipo de habitação do cliente (própria, alugada, hipotecada, etc.).
- ***loan\_amnt:*** Montante do empréstimo.
- ***loan\_intent:*** Finalidade do empréstimo.
- ***loan\_int\_rate:*** Taxa de juro do empréstimo.
- ***loan\_percent\_income:*** Percentagem do rendimento anual do cliente que é o montante do empréstimo.
- ***cb\_person\_cred\_hist\_length:*** Número de anos de histórico de crédito do cliente.
- ***credit\_score:*** Pontuação de crédito do cliente.
- ***previous\_loan\_defaults\_on\_file:*** Se o cliente tem empréstimos anteriores com incumprimento.
- ***tax:*** Indicador de imposto para o empréstimo.
- ***loan\_status:*** Estado do empréstimo (concedido, pendente ou recusado).



O *dataset* contém variáveis categóricas e numéricas, sendo que as variáveis categóricas são representadas por strings e as variáveis numéricas são representadas por números inteiros ou *doubles*.

A estrutura do *dataset* é a seguinte:

```
data person name person age person credit_limit person income person emp_emp person home_ownership loan_amount loan_intent loan_int_rate loan_percent_income id person_cred hist_length credit_score previous_loan_defaults_on_file lat loan_status
05-12-1999 Victoria Klenz 26.0 Associate 47573.0 8.0 MORTGAGE 1600.0 MEDICAL 8.49 8.86 2.0 0 Yes 1 Rejected
06-06-1999 Pedro Danilo Valtim 29.0 Bachelor 21270.0 9.0 RENT 1270.0 PERSONAL 18.27 8.58 8.0 0 Yes 1 Rejected
28-08-2001 Paloma Isabel Prats 34.0 Associate 53541.0 4.0 RENT 3400.0 VEH 18.0 9.18 3.0 0 Yes 1 Pending
10-03-1998 Eric Wilson Eijido 27.0 Associate 18124.0 5.0 PERSONAL 2200.0 EDUCATION 11.28 8.22 5.0 0 Yes 1 Pending
21-05-1987 Giovanni Martin Califa 38.0 Bachelor 47222.0 14.0 RENT 12500.0 DEBT_CONSOLIDATION 18.48 8.27 14.0 0 No 1 Pending
05-10-1994 Miguel Angel Hernandez 21.0 Associate 20207.0 8.0 RENT 2000.0 PERSONAL 9.99 11.8 6.0 0 Yes 1 Rejected
17-08-2000 Daniel Pedro Abello 25.0 Bachelor 32501.0 4.0 RENT 4300.0 MEDICAL 11.86 8.15 3.0 0 Yes 1 Pending
10-06-2004 Carlos Roberto Diaz 30.0 Associate 18477.0 8.0 MORTGAGE 1600.0 EDUCATION 11.18 8.2 2.0 0 No 1 Rejected
12-08-2002 Livanny Concha 23.0 High School 48792.0 8.0 MORTGAGE 16000.0 EDUCATION 11.61 8.52 4.0 0 Yes 1 Rejected
05-11-2002 Josely Velasco 22.0 Bachelor 30070.0 8.0 RENT 3000.0 EDUCATION 8.05 8.48 2.0 0 Yes 1 Rejected
12-06-2003 Isidoro Pulver 22.0 Associate 77908.0 4.0 MORTGAGE 1200.0 PERSONAL 13.43 8.12 3.0 0 Yes 1 Rejected
18-05-2009 Carlos Hernandez 27.0 Associate 22218.0 5.0 PERSONAL 2000.0 MEDICAL 11.79 8.6 8.0 0 Yes 1 Rejected
09-04-2003 Henrique de Santa Maria Particarrere 22.0 Associate 45604.0 2.0 MORTGAGE 4000.0 DEBT_CONSOLIDATION 5.42 8.67 2.0 0 No 1 Pending
06-04-2009 Alicia Maria Pulido 36.0 Bachelor 22008.0 12.0 RENT 10000.0 PERSONAL 15.18 8.1 1.0 0 No 1 Pending
03-08-1993 Alvaro Neri Fernandez 32.0 Bachelor 22605.0 11.0 RENT 10000.0 EDUCATION 18.75 8.84 7.0 0 No 1 Pending
18-01-1999 Lilia Maria Sanchez 38.0 High School 12079.0 5.0 MORTGAGE 2000.0 EDUCATION 11.28 8.22 5.0 0 Yes 1 Pending
23-02-1991 Lando Neme 34.0 Associate 10214.0 12.0 RENT 3000.0 VEHICLE 11.83 8.85 5.0 0 Yes 1 Rejected
12-09-2006 Jerome Jemini 26.0 High School 48665.0 12.0 RENT 10000.0 EDUCATION 9.79 8.25 7.0 0 Yes 1 Pending
03-06-2004 Mariella Graziosi 21.0 Bachelor 24865.0 8.0 RENT 2000.0 MEDICAL 11.61 8.5 3.0 0 Yes 1 Rejected
14-07-2001 Eder Polixia Pineda 22.0 Bachelor 44720.0 8.0 RENT 1117.0 VEHICLE 17.18 8.87 3.0 0 Yes 1 Rejected
```

Figura 1.1.: Estrutura do *dataset* Loan.

## 1.2. KNIME Workflow

A estrutura do *workflow* para o *loan\_dataset*, desenvolvido na plataforma *KNIME*, é a seguinte:



Figura 1.2.: *KNIME*: Estrutura do *workflow* desenvolvido para o *dataset* Loan.

## 1.3. Análise Preliminar dos Dados

A análise preliminar dos dados é uma etapa importante no processo de análise de dados, pois permite compreender a estrutura e as características do *dataset*. Primeiramente, começou-se por utilizar nodos de leitura para importar os dados dos ficheiros *loan\_train.csv* e *loan\_test.csv*, concatenando-os para formar um único *dataset*.




Figura 1.3.: *KNIME*: Nós de leitura do *dataset* Loan.

### 1.3.1. Linear e Rank Correlations

Após a leitura dos dados, foram utilizados nós de exploração para analisar a estrutura do *dataset*: utilizou-se o nó *Linear Correlation* para calcular a correlação entre as variáveis numéricas, e o nó *Rank Correlation* para calcular a correlação entre as variáveis categóricas.




Figura 1.4.: *KNIME*: Nós de exploração do *dataset* Loan.

Através destes nós, foi possível observar a relação entre as variáveis e identificar possíveis padrões nos dados. Esta análise pode revelar-se bastante útil na decisão sobre quais as *features* a incluir nos modelos de *Machine Learning*. A matriz de *linear correlation* revela uma correlação negativa entre a variável *loan\_status* e variáveis como *loan\_percent\_income* e *loan\_int\_rate*, indicando que um maior esforço financeiro ou uma taxa de juro mais elevada estão associados a uma maior probabilidade de incumprimento. Destaca-se também uma correlação positiva entre *person\_age* e *cb\_person\_cred\_hist\_length*, coerente com a expectativa de que indivíduos mais velhos possuam um histórico de crédito mais extenso.

A matriz de *rank correlation* apresenta padrões semelhantes, sendo, no entanto, mais robusta a *outliers* e capaz de identificar relações monotónicas não necessariamente lineares.

Estas análises constituem uma base relevante para a seleção de variáveis, permitindo identificar possíveis redundâncias e destacar variáveis com potencial preditivo para os modelos de *Machine Learning*.




Figura 1.5.: *KNIME*: Matriz de *Linear Correlation* do *dataset* Loan.




Figura 1.6.: *KNIME*: Matriz de *Rank Correlation* do *dataset* Loan.




Figura 1.7.: *KNIME*: Estatísticas descritivas do *dataset* Loan.

Analisando as estatísticas descritivas do *dataset*, antes do pré-processamento, é possível observar:

### 1.3.2. Missing Values




Figura 1.8.: *KNIME*: Distribuição de *Missing Values* do *dataset* Loan.

Tal como no *loan\_amnt*, as restantes variáveis apresentam uma percentagem de *missing values* bastante elevada, o que tem que ser tratado de forma a não se perder os dados, mas também não se introduzir valores incompletos nos modelos.

### 1.3.3. Outliers




Figura 1.9.: *KNIME*: Boxplot do *dataset* Loan.

Através do *boxplot* é possível observar a presença de *outliers*, especialmente na variável *person\_income*, que apresenta uma distribuição assimétrica, com valores extremos que podem influenciar os resultados.

### 1.3.4. Statistics

| Column                     | Exclude Column           | Minimum | Maximum | Mean      | Standard Deviation | Variance       | Skewness |
|----------------------------|--------------------------|---------|---------|-----------|--------------------|----------------|----------|
| person_age                 | <input type="checkbox"/> | 20      | 144     | 27.762    | 6.030              | 36.356         | 2.510    |
| person_income              | <input type="checkbox"/> | 0       | 7200766 | 79530.638 | 76798.314          | 5897981080.271 | 31.827   |
| person_emp_exp             | <input type="checkbox"/> | 0       | 125     | 5.406     | 6.044              | 36.527         | 2.556    |
| loan_amnt                  | <input type="checkbox"/> | 0       | 35000   | 9526.746  | 6332.533           | 40100968.760   | 1.165    |
| loan_int_rate              | <input type="checkbox"/> | 5.420   | 20      | 11.007    | 2.977              | 8.864          | 0.212    |
| loan_percent_income        | <input type="checkbox"/> | 0       | 2.489   | 0.143     | 0.116              | 0.013          | 7.294    |
| cb_person_cred_hist_length | <input type="checkbox"/> | 2       | 30      | 5.865     | 3.876              | 15.025         | 1.627    |
| credit_score               | <input type="checkbox"/> | 390     | 850     | 632.604   | 50.426             | 2542.822       | -0.612   |
| tax                        | <input type="checkbox"/> | 1       | 1       | 1         | 0                  | 0              | 0        |

Figura 1.10.: *KNIME*: Estatísticas do *dataset* Loan.

Na tabela de estatísticas, é possível observar máximos e mínimos de cada variável, bem como a média e o desvio padrão, o que permite perceber a distribuição dos dados.

### 1.3.5. Standard Deviation




Figura 1.11.: *KNIME*: Desvio padrão do *dataset* Loan.

Através do desvio padrão, é possível observar a dispersão dos dados em relação à média, o que pode ajudar a identificar variáveis com maior variabilidade e, portanto, maior potencial preditivo. Neste caso, a variável *person\_income* apresenta o maior desvio padrão, o que indica uma grande variação nos rendimentos dos clientes.

## 1.4. Pré-Processamento dos Dados

O pré-processamento dos dados é uma etapa crucial na análise de dados, pois permite preparar os dados para a construção de modelos de *Machine Learning*. Neste caso, existiam algumas discrepâncias nos dados, como valores *Missing*, *outliers*, valores sem sentido (como idades acima dos 100 anos, empréstimos nulos, etc.), linhas duplicadas, vários nomes para a mesma categoria em variáveis categóricas, entre outros.

Para lidar com estes problemas, estabeleceu-se um fluxo de trabalho que inclui as seguintes etapas:




Figura 1.12.: KNIME: Fluxo de trabalho do pré-processamento do *dataset* Loan.

- **Column Filter:** Remoção de colunas irrelevantes, neste caso, *date*, *person\_name*, *gender* e *tax*, que não são relevantes para a previsão do estado do empréstimo.
- **Numeric Outliers:** Tratamento de *outliers* nos campos *age*, *loan\_amnt* e *person\_income*, substituindo por valores mais aproximados.
- **Math Formula:** Criação da variável *debt-to-income ratio*, que é a razão entre o montante do empréstimo e o rendimento anual do cliente.
- **Expression Row Filter:** Limitação da idade para menos de 90 anos, limitação dos anos de experiência profissional para valores maiores ou iguais a 0 e menores ou iguais à idade do cliente menos 16 anos, e limitação do montante do empréstimo para valores maiores ou iguais a 500.
- **Rule Engine:** Uniformização dos valores categóricos, como *person\_education*, *person\_home\_ownership* e *loan\_intent*, para que todos os valores sejam representados da mesma forma, evitando duplicações.
- **Duplicate Row Filter:** Remoção de linhas duplicadas.
- **Missing Value:** Tratamento de valores *Missing* nas variáveis, com uso de um *loop* para substituir os valores *Missing* pela *moving average*.
- **Numeric Binner:** Criação de bins para a idade do cliente, com o objetivo de agrupar as faixas etárias em menores que 30, entre 30 e 50, e maiores que 50 anos.

## 1.5. Análise de Dados Após Pré-Processamento

Após o pré-processamento dos dados, foram realizadas análises semelhantes às anteriores, com o objetivo de verificar se as alterações realizadas tiveram impacto positivo nos dados.

### 1.5.1. Missing Values




Figura 1.13.: *KNIME*: Distribuição de *Missing Values* do *dataset* Loan após pré-processamento.

Após o pré-processamento, a percentagem de *missing values* diminuiu completamente, de forma a que nenhuma variável tenha valores *Missing*.

### 1.5.2. Outliers




Figura 1.14.: *KNIME*: *Boxplot* do *dataset* Loan após pré-processamento.

Após o pré-processamento, a presença de *outliers* diminuiu consideravelmente, com a maioria das variáveis apresentando uma distribuição mais simétrica.

### 1.5.3. Statistics

| Column                     | Exclude Column           | Minimum | Maximum    | Mean      | Standard Deviation | Variance       | Skewness |
|----------------------------|--------------------------|---------|------------|-----------|--------------------|----------------|----------|
| person_age                 | <input type="checkbox"/> | 20      | 39         | 27.249    | 4.736              | 22.429         | 0.927    |
| person_income              | <input type="checkbox"/> | 0       | 167426.500 | 74796.255 | 38134.686          | 1454254282.768 | 0.814    |
| person_emp_exp             | <input type="checkbox"/> | 0       | 23         | 4.993     | 5.022              | 25.223         | 1.207    |
| loan_amnt                  | <input type="checkbox"/> | 500     | 22667.500  | 9372.191  | 5744.033           | 32993916.083   | 0.790    |
| loan_int_rate              | <input type="checkbox"/> | 5.420   | 20         | 11.003    | 2.967              | 8.801          | 0.212    |
| loan_percent_income        | <input type="checkbox"/> | 0       | 2.473      | 0.143     | 0.114              | 0.013          | 7.193    |
| cb_person_cred_hist_length | <input type="checkbox"/> | 2       | 24         | 5.659     | 3.476              | 12.085         | 1.211    |
| credit_score               | <input type="checkbox"/> | 390     | 768        | 632.037   | 49.928             | 2492.843       | -0.631   |
| debt-to-income             | <input type="checkbox"/> | 0.006   | 0.664      | 0.139     | 0.083              | 0.007          | 1.024    |

Figura 1.15.: *KNIME*: Estatísticas do *dataset* Loan após pré-processamento.

Após o pré-processamento, as estatísticas descritivas mostram uma distribuição mais equilibrada e coerente dos dados, com valores mais próximos da média e menos dispersão.

### 1.5.4. Standard Deviation




Figura 1.16.: *KNIME*: Desvio padrão do *dataset* Loan após pré-processamento.

Após o pré-processamento, o desvio padrão das variáveis diminuiu, indicando uma menor dispersão dos dados em relação à média. A variável *person\_age* passou a ser a variável com maior desvio padrão, o que indica uma maior variação na idade dos clientes.

### 1.5.5. Linear e Rank Correlations

Por fim, foi avaliada a correlação entre as diversas variáveis do conjunto de dados. Para tal, e como foi anteriormente realizado, recorreram-se aos nodos *Linear Correlation* e *Rank Correlation*.






Figura 1.17.: *KNIME*: Matriz de *Linear Correlation* do *dataset* Loan após pré-processamento.




Figura 1.18.: *KNIME*: Matriz de *Rank Correlation* do *dataset* Loan após pré-processamento.

## 1.6. Modelos

Nota: Para consultar as matrizes de confusão de cada modelo, consulte o capítulo Apêndices (A).

Após o pré-processamento dos dados, foram criados diversos modelos de *Machine Learning* para prever o estado do empréstimo.




Figura 1.19.: *KNIME*: Modelos de *Machine Learning* utilizados no *dataset* Loan.

### 1.6.1. Decision Tree




Figura 1.20.: *KNIME*: Modelo de *Decision Tree* do *dataset* Loan.

Neste modelo, não foram efetuados aperfeiçoamentos, não havendo tratamento de dados, *pruning*, ou *feature selection*. O modelo foi construído com os dados pré-processados, e a variável alvo foi definida como *loan\_status*. Assim como será verificado nos restantes modelos, são sempre efetuadas dois tipos de validação - *cross validation* e *hold-out validation*.

Os resultados obtidos foram de *accuracy* de **51.32%** para a *hold-out validation* e **50.81%** para a *cross validation*.

## 1.6.2. Linear Regression

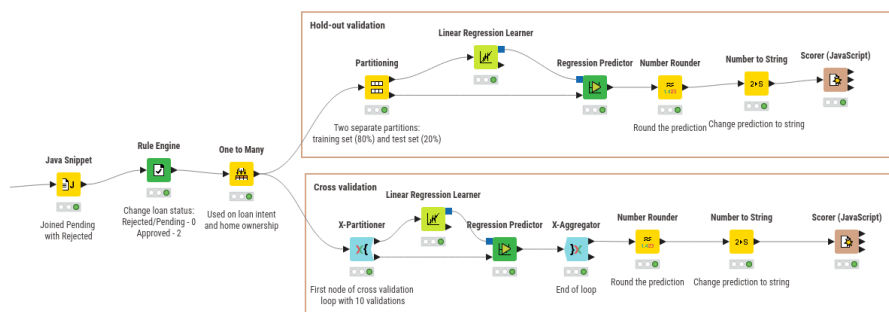


Figura 1.21.: KNIME: Modelo de *Linear Regression* do dataset Loan.

Neste modelo, foram utilizados os mesmos dados do modelo anterior, mas foram aplicadas algumas alterações. A equipa de trabalho apercebeu-se que a maior parte dos dados enquadravam-se no *status* Aprovado, o que poderia levar a um viés nos resultados. Por conseguinte, foi aplicado um *Snippet* de Java para unir os estados Pendente e Recusado, de forma a que o modelo não fosse enviesado para o estado Aprovado.

De seguida, como a regressão linear não aceita variáveis categóricas, foi necessário converter a variável categórica de *status* numa variável numérica com o uso do nodo *Rule Engine*, e depois aplicar o nodo *One-To-Many* nos *loan\_intent* e *person\_home\_ownership*, para que as estas variáveis categóricas também fossem convertidas em variáveis numéricas.

No fim, foi necessário aplicar o *Number Rounder* e *Number To String* para converter a variável alvo e a sua previsão para o formato correto.

Os resultados obtidos foram de *accuracy* de **84.18%** para a *hold-out validation* e **84.55%** para a *cross validation*.

## 1.6.3. Logistic Regression




Figura 1.22.: KNIME: Modelo de *Logistic Regression* do dataset Loan.

Neste modelo, também foi aplicada a união dos estados Pendente e Recusado, tal como no anterior. De seguida, foi necessário usar om nodo *Normalizer* para normalizar *features* numéricas, convertendo em valores entre 0 e 1.

Os resultados obtidos foram de *accuracy* de **84.60%** para a *hold-out validation* e **84.67%** para a *cross validation*.

#### 1.6.4. Clustering




Figura 1.23.: KNIME: Modelo de *Clustering* do *dataset* Loan.

Neste modelo, começou-se pela mesma união dos estados Pendente e Recusado, tal como nos anteriores. De seguida, usou-se o nodo *Normalizer* para normalizar *features* numéricas, convertendo em valores entre 0 e 1. Seguidamente, aplicou-se o nodo *Auto-Binner* para criar *bins* para as variáveis *person\_age*, *person\_cred\_hist\_length* e *person\_emp\_exp*.

Foi usado o nodo *K-Means* para criar dois *clusters* – um para os empréstimos recusados/pendentes e outro para os empréstimos aprovados. Por fim, foi aplicado o *Rule Engine* para renomear os *clusters* para as categorias correspondentes.

Os resultados obtidos foram de *accuracy* de **35.81%** para a *hold-out validation* e **47.13%** para a *cross validation*, sendo este o modelo com pior desempenho.

#### 1.6.5. MLP - Multi-Layer Perceptron




Figura 1.24.: KNIME: Modelo de *MLP* do *dataset* Loan.

Neste modelo, também foi aplicada a união dos estados Pendente e Recusado, tal como nos anteriores. De seguida, foi usado um nodo *Column Filter* para remover variáveis categóricas, exceto a variável alvo. Foi necessário usar o nodo *Normalizer* para normalizar *features* numéricas, convertendo em valores entre 0 e 1. Seguidamente, no *Learner*, foram definidas 100 iterações máximas, 3 camadas ocultas e 10 neurónios por camada.

Os resultados obtidos foram de *accuracy* de **84.50%** para a *hold-out validation* e **84.82%** para a *cross validation*.

Também foram adicionados *scatter plots* para ambas as validações, com  $x = \text{debt-to-income ratio}$  e  $y = P = \text{loan\_status} = \text{Approved}$ .




Figura 1.25.: *KNIME*: Gráfico de dispersão do *dataset* Loan na *hold-out validation*.




Figura 1.26.: *KNIME*: Gráfico de dispersão do *dataset* Loan na *cross validation*.

### 1.6.6. Decision Tree com *feature selection*

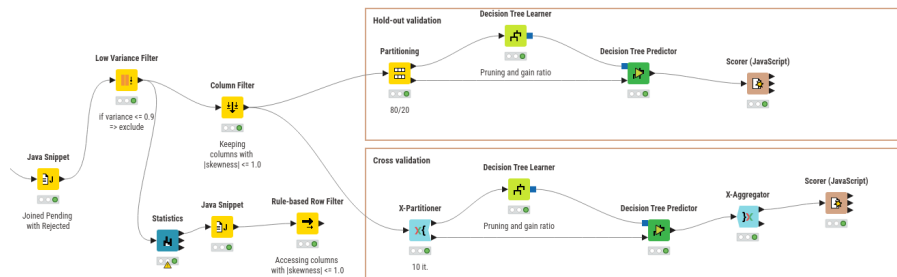


Figura 1.27.: *KNIME*: Modelo de *Decision Tree* com *feature selection* do *dataset* Loan.

Neste modelo, foi aplicada a mesma união dos estados Pendente e Recusado, tal como nos anteriores. Seguidamente, foi usado um nodo *Low Variance Filter* para remover variáveis com variância menor ou igual a 0,9. Utilizou-se um nodo *Statistics* para calcular a assimetria (*skewness*), seguido de nodos *Java Snippet* e *Rule-based Column Filter* para filtrar as *features* cujo módulo da assimetria fosse menor ou igual a 1,0. Com estas informações, recorreu-se a um nodo *Column Filter* para remover as colunas cuja assimetria não estivesse em vigor com a regra anterior. No *Learner*, utilizou-se o *pruning* e *gain ratio*.

Os resultados obtidos foram de *accuracy* de **85.04%** para a *hold-out validation* e **85.16%** para a *cross validation*.

### 1.6.7. Random Forest




Figura 1.28.: KNIME: Modelo de *Random Forest* do *dataset* Loan.

Neste modelo, também foi aplicada a união dos estados Pendente e Recusado, tal como nos anteriores. De seguida, foram aplicados *Backwards Feature Elimination* e *Forward Feature Elimination* para selecionar as variáveis mais relevantes:

#### Backwards Feature Elimination




Figura 1.29.: KNIME: Modelo de *Backwards Feature Elimination* do *dataset* Loan.

Nesta eliminação, foi usado o modelo *Naive Bayes* para calcular a importância das variáveis, usando, como métrica, a *accuracy*. Através do nodo *Feature Selection Filter*, foram selecionadas as variáveis com *score* maior ou igual a 0,87. As variáveis selecionadas foram:

- *loan\_int\_rate*
- *previous\_loan\_defaults\_on\_file*

- *debt-to-income*
- *loan\_status* (estática)

## Forward Feature Elimination




Figura 1.30.: *KNIME*: Modelo de *Forward Feature Elimination* do dataset Loan.

Exatamente como na eliminação anterior, foi usado o modelo *Naive Bayes* para calcular a importância das variáveis, usando, como métrica, a *accuracy*. Através do nodo *Feature Selection Filter*, foram selecionadas as variáveis com *score* maior ou igual a 0,87, sendo estas as mesmas que na eliminação anterior.

Os resultados obtidos foram:

- ***Backwards Feature Elimination***: *accuracy* de **87.52%** para a *hold-out validation* e **87.66%** para a *cross validation*;
- ***Forward Feature Elimination***: *accuracy* de **87.52%** para a *hold-out validation* e **87.66%** para a *cross validation*.

Como, em ambos os casos, as variáveis selecionadas foram as mesmas, acabaram por ter os mesmos resultados. Contudo, este foi o modelo com melhor desempenho.

## 1.7. Análise dos Modelos

Na tabela seguinte, são apresentados, em sumário, os resultados obtidos para cada um dos modelos de *Machine Learning* utilizados, com as respetivas *accuracies* em *hold-out validation* e *cross validation*.



| <b>Modelo</b>                                            | <b><i>Hold-out Validation</i></b> | <b><i>Cross Validation</i></b> |
|----------------------------------------------------------|-----------------------------------|--------------------------------|
| <i>Decision Tree</i>                                     | 51.32%                            | 50.81%                         |
| <i>Linear Regression</i>                                 | 84.18%                            | 84.55%                         |
| <i>Logistic Regression</i>                               | 84.60%                            | 84.67%                         |
| <i>Clustering</i>                                        | 35.81%                            | 47.13%                         |
| <i>MLP</i>                                               | 84.50%                            | 84.82%                         |
| <i>Decision Tree com Feature Selection</i>               | 85.04%                            | 85.16%                         |
| <i>Random Forest com Feature Elimination (Backwards)</i> | 87.52%                            | 87.66%                         |
| <i>Random Forest com Feature Elimination (Forward)</i>   | 87.52%                            | 87.66%                         |

Tabela 1.1.: Resultados dos modelos de *Machine Learning* do *dataset Loan*

É possível observar que o modelo de *Random Forest* com *feature selection* obteve os melhores resultados, enquanto que o modelo de *Clustering* obteve os piores resultados. Acreditamos que isto se deve ao facto de o modelo de *Random Forest* ser um modelo mais robusto e capaz de lidar com variáveis categóricas, enquanto que o modelo de *Clustering* é mais sensível a *outliers* e não é capaz de lidar com variáveis categóricas. Além disso, o modelo de *Random Forest* com *feature selection* foi capaz de identificar as variáveis mais relevantes para a previsão do estado do empréstimo, o que pode ter contribuído

## 2. *World Happiness Index and Inflation Dataset*

### 2.1. *Dataset*

O segundo *dataset* explorado neste projeto foi o *World Happiness Index and Inflation Dataset*, que contém dados sobre o índice de felicidade mundial e a inflação em diversos países. Este *dataset* foi obtido a partir do *Kaggle*, cujo *link* pode ser consultado na bibliografia (A.2).

O *dataset* está contido no ficheiro `WHI_Inflation.csv`, contendo 1232 linhas e 16 colunas com os seguintes dados:

- **Country:** Nome do país (*string*);
- **Year:** Ano de referência (*integer*);
- **Headline Consumer Price Inflation:** Taxa de inflação do consumidor (*double*);
- **Energy Consumer Price Inflation:** Taxa de inflação do consumidor de energia (*double*);
- **Food Consumer Price Inflation:** Taxa de inflação do consumidor de alimentos (*double*);
- **Official Core Consumer Price Inflation:** Taxa de inflação do consumidor oficial (*double*);
- **Producer Price Inflation:** Taxa de inflação do produtor (*double*);
- **GDP deflator Index growth rate:** Taxa de crescimento do índice do deflator do PIB (*double*);
- **Continent/Region:** Continente ou região do país (*string*);
- **Score:** Pontuação de felicidade do país (*double*);
- **GDP per capita:** PIB per capita do país (*double*);
- **Social support:** Suporte social do país (*double*);
- **Healthy life expectancy at birth:** Expectativa de vida saudável ao nascer (*double*);
- **Freedom to make life choices:** Liberdade para fazer escolhas de vida (*double*);
- **Generosity:** Generosidade do país (*double*);
- **Perceptions of corruption:** Percepções de corrupção do país (*double*).

O *dataset* contém dados de vários países ao longo de vários anos, permitindo analisar a relação entre o índice de felicidade e a inflação em diferentes contextos. A variável alvo a prever é o *Score*, que representa a pontuação de felicidade do país. Visto que o *dataset* contém maioritariamente dados numéricos, a abordagem relativamente aos modelos será diferente da anterior.

## 2.2. KNIME Workflow

O fluxo de trabalho do *dataset World Happiness Index and Inflation*, também desenvolvido na plataforma *KNIME*, é semelhante ao do *dataset Loan*:




Figura 2.1.: *KNIME*: Fluxo de trabalho do *dataset World Happiness Index and Inflation*.

Neste caso, o pré-processamento de dados foi efetuado de maneira diferente em cada modelo, pelo que se encontra anexado a cada um destes, como veremos nos próximos capítulos.

## 2.3. Análise Preliminar dos Dados

Assim como no *dataset* anterior, foram realizadas análises preliminares aos dados, de forma a perceber a sua distribuição e características. Começou-se por utilizar um *CSV Reader* para ler o *dataset*, e, de seguida, recorremos aos nodos de *Rank Correlation* e *Linear Correlation* para calcular a correlação entre as variáveis.

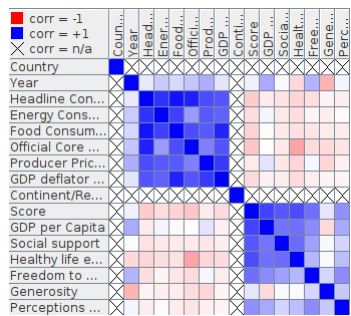


Figura 2.2.: *KNIME*: Matriz de *Linear Correlation* do *dataset* World Happiness Index and Inflation.

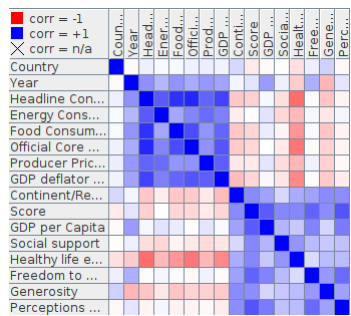


Figura 2.3.: *KNIME*: Matriz de *Rank Correlation* do *dataset* World Happiness Index and Inflation.

Seguidamente, foram utilizados nodos de estatísticas descritivas para analisar os dados de forma mais aprofundada.

### 2.3.1. Data Exploration

| Column                                 | Exclude Column           | Minimum | Maximum | Mean     | Standard Deviation | Variance | Skewness | Kurtosis | Overall Sum | No. zeros | No. missing | No. NaN | No. <= | No. >= | Histogram |
|----------------------------------------|--------------------------|---------|---------|----------|--------------------|----------|----------|----------|-------------|-----------|-------------|---------|--------|--------|-----------|
| Year                                   | <input type="checkbox"/> | 2015    | 2023    | 2018.895 | 2.855              | 6.526    | 0.044    | -1.204   | 2487279     | 0         | 0           | 0       | 0      | 0      |           |
| Headline Consumer Price Inflation      | <input type="checkbox"/> | -3.753  | 557.210 | 7.395    | 25.166             | 633.323  | 13.680   | 247.231  | 8874.534    | 0         | 32          | 0       | 0      | 0      |           |
| Energy Consumer Price Inflation        | <input type="checkbox"/> | -23.880 | 306.432 | 6.424    | 16.882             | 275.278  | 8.558    | 118.685  | 7002.414    | 2         | 142         | 0       | 0      | 0      |           |
| Food Consumer Price Inflation          | <input type="checkbox"/> | -22.030 | 601.020 | 8.030    | 26.170             | 684.462  | 14.549   | 273.280  | 9074.006    | 1         | 102         | 0       | 0      | 0      |           |
| Official Core Consumer Price Inflation | <input type="checkbox"/> | -26.619 | 58.852  | 3.513    | 5.514              | 30.400   | 3.734    | 36.490   | 2079.257    | 0         | 498         | 0       | 0      | 0      |           |
| Producer Price Inflation               | <input type="checkbox"/> | -53.340 | 126.477 | 5.942    | 13.679             | 187.123  | 2.942    | 22.775   | 4462.411    | 0         | 463         | 0       | 0      | 0      |           |
| GDP deflator index growth rate         | <input type="checkbox"/> | -26.100 | 812.247 | 7.070    | 31.623             | 1000.026 | 19.087   | 433.582  | 8951.789    | 0         | 21          | 0       | 0      | 0      |           |
| Score                                  | <input type="checkbox"/> | 1.859   | 7.842   | 5.499    | 1.135              | 1.289    | -0.149   | -0.818   | 6774.769    | 0         | 0           | 0       | 0      | 0      |           |

Figura 2.4.: *KNIME*: Estatísticas do *dataset* World Happiness Index and Inflation - parte 1

|                                  |                          |   |       |       |       |       |        |        |          |    |   |   |   |   |                                                                                     |
|----------------------------------|--------------------------|---|-------|-------|-------|-------|--------|--------|----------|----|---|---|---|---|-------------------------------------------------------------------------------------|
| GDP per Capita                   | <input type="checkbox"/> | 0 | 2.209 | 1.031 | 0.452 | 0.205 | -0.110 | -0.438 | 1289.904 | 6  | 0 | 0 | 0 | 0 |  |
| Social support                   | <input type="checkbox"/> | 0 | 1.644 | 1.057 | 0.333 | 0.111 | -0.672 | 0.151  | 1301.780 | 9  | 0 | 0 | 0 | 0 |  |
| Healthy life expectancy at birth | <input type="checkbox"/> | 0 | 1.141 | 0.589 | 0.244 | 0.060 | -0.357 | -0.593 | 725.346  | 9  | 0 | 0 | 0 | 0 |  |
| Freedom to make life choices     | <input type="checkbox"/> | 0 | 0.772 | 0.459 | 0.156 | 0.024 | -0.682 | 0.088  | 585.972  | 9  | 0 | 0 | 0 | 0 |  |
| Generosity                       | <input type="checkbox"/> | 0 | 0.838 | 0.196 | 0.113 | 0.013 | 1.185  | 2.748  | 241.651  | 9  | 0 | 0 | 0 | 0 |  |
| Perceptions of corruption        | <input type="checkbox"/> | 0 | 0.587 | 0.133 | 0.115 | 0.013 | 1.538  | 1.981  | 164.282  | 10 | 1 | 0 | 0 | 0 |  |

Figura 2.5.: *KNIME*: Estatísticas do *dataset* World Happiness Index and Inflation - parte 2

Através da tabela de estatísticas, é possível observar máximos e mínimos de cada variável, bem como a média e o desvio padrão, o que permite perceber a distribuição dos dados.

### 2.3.2. Standard Deviation




Figura 2.6.: *KNIME*: Desvio padrão do *dataset* World Happiness Index and Inflation.

Através do desvio padrão, é possível observar a dispersão dos dados em relação à média, o que pode ajudar a identificar variáveis com maior variabilidade e, portanto, maior potencial preditivo.

### 2.3.3. Missing Values




Figura 2.7.: *KNIME*: Distribuição de *Missing Values* do *dataset* World Happiness Index and Inflation.

Através do gráfico de *pie chart*, é possível observar a percentagem de *missing values* em cada variável, o que pode ajudar a identificar variáveis com maior quantidade de dados faltantes e, portanto, maior necessidade de tratamento.

### 2.3.4. Outliers




Figura 2.8.: *KNIME*: *Boxplot* do *dataset* World Happiness Index and Inflation.

Através do gráfico de *boxplot*, é possível observar a presença de *outliers* em cada variável, o que pode ajudar a identificar variáveis com maior quantidade de dados discrepantes e, portanto, maior necessidade de tratamento - como, neste caso, as variáveis *GDP per capita* e *Food Consumer Price Inflation*.

## 2.4. Modelos

Assim como no *dataset* anterior, foram criados diversos modelos de *Machine Learning* para prever o índice de felicidade mundial.




Figura 2.9.: *KNIME*: Modelos de *Machine Learning* utilizados no *dataset* World Happiness Index and Inflation.

Tal como mencionado anteriormente, o pré-processamento dos dados foi efetuado de maneira diferente em cada modelo, pelo que se encontra anexado a cada um destes. Além disso, devido ao tipo diferente de dados, recorreu-se a outros modelos de *Machine Learning*.

## 2.4.1. Random Forest

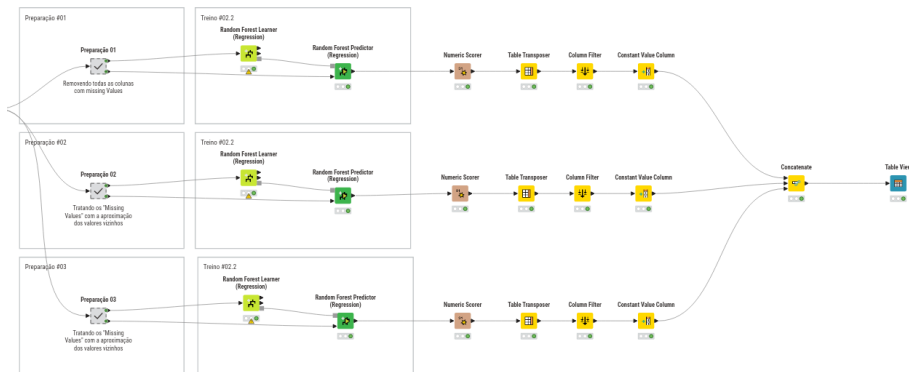


Figura 2.10.: *KNIME*: Modelo de *Random Forest* do *dataset* World Happiness Index and Inflation.

Neste modelo, foram aplicadas três abordagens distintas de preparação dos dados com o objetivo de investigar qual seria a maneira mais eficaz de lidar com *Missing Values*. Embora as estruturas gerais das três abordagens sejam similares, a forma como o nó de *Missing Values* foi utilizado variou significativamente entre elas.

Na primeira preparação, optou-se por não realizar nenhum tipo de imputação: todas as linhas que continham valores ausentes foram simplesmente removidas do conjunto de dados. Essa estratégia tem a vantagem de preservar a integridade estatística do conjunto já que não são inseridos valores artificiais. No entanto, essa escolha também apresenta uma desvantagem importante, especialmente em contextos

com *datasets* de tamanho reduzido, pois a remoção de registos com dados faltantes pode significar perda significativa de informações relevantes para o treinamento.

Na segunda preparação, os valores ausentes foram preenchidos com o valor mais frequente da coluna correspondente, e, em alguns casos, interpolação linear para completar lacunas em variáveis contínuas. Essa abordagem evita a perda de dados, mantendo todas as observações no conjunto, mas introduz valores que podem não refletir fielmente os padrões originais dos dados.

Já na terceira preparação, adotou-se a técnica de média móvel *Moving Average* para imputar os valores faltantes. Esse método, por levar em consideração os valores vizinhos, tende a gerar substituições mais suavizadas e coerentes com a tendência local da variável. Assim como a abordagem anterior, esta também evita perdas de informação, com a vantagem adicional de reduzir o risco de introdução de ruído estatístico que possa comprometer o desempenho do modelo.




Figura 2.11.: *KNIME*: Preparação de dados do *dataset* World Happiness Index and Inflation.

Após a aplicação dos nodos de *Random Forest*, foram obtidos os seguintes resultados:

| RowID | R^2<br>Number (double) | mean absolute error<br>Number (double) | Tratamento<br>String       |
|-------|------------------------|----------------------------------------|----------------------------|
| Row0  | 0.82                   | 0.308                                  | Removendo Missing Values   |
| Row1  | 0.826                  | 0.365                                  | Valor mais frequente       |
| Row2  | 0.825                  | 0.37                                   | Media dos Valores Proximos |

Figura 2.12.: *KNIME*: Resultados do modelo de *Random Forest* do *dataset* World Happiness Index and Inflation.

Como podemos verificar, a preparação de dados 2 (substituição por valor mais frequente e interpolação linear) obteve os melhores resultados. Acreditamos que, embora com essa abordagem apresente uma quantidade de ruído estatístico, demonstra melhores resultados pelo facto de existirem mais casos de estudo para o modelo aprender.



### 2.4.2. Polynomial Regression

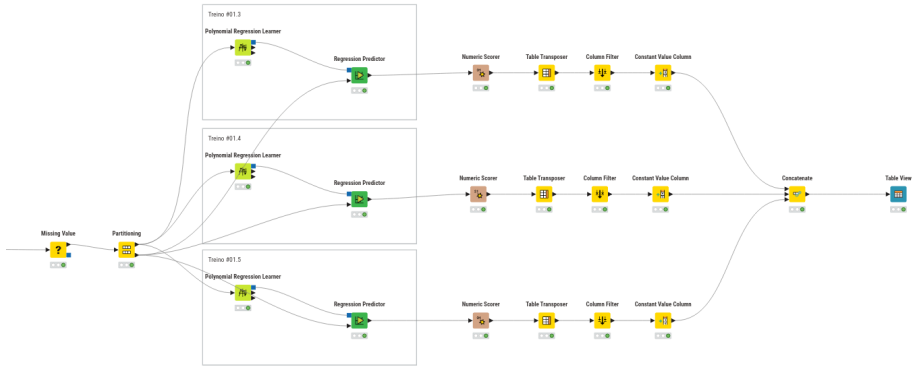


Figura 2.13.: KNIME: Modelo de *Polynomial Regression* do dataset World Happiness Index and Inflation.

Neste modelo, foram utilizados três nodos de *Polynomial Regression*, com diferentes graus de polinómio. O primeiro modelo utilizou um *Maximum Polynomial Degree* de 1, 2 e 3 com o objetivo de determinar qual seria o melhor grau de complexidade para representar esse problema. Após a aplicação dos nodos de *Polynomial Regression*, foram obtidos os seguintes resultados:

| RowID | R^2<br>Number (double) | mean absolute error<br>Number (double) | Tratamento<br>String |
|-------|------------------------|----------------------------------------|----------------------|
| Row0  | 0.748                  | 0.441                                  | Grau 01              |
| Row1  | 0.349                  | 0.476                                  | Grau 02              |
| Row2  | -293.602               | 1.464                                  | Grau 03              |

Figura 2.14.: KNIME: Resultados do modelo de *Polynomial Regression* do dataset World Happiness Index and Inflation.

Como podemos observar, o modelo polinomial de grau 1 apresentou os melhores resultados entre as variações testadas, enquanto o modelo de grau 3 obteve valores negativos de desempenho. Isso se deve ao fato de que, ao aumentar o grau do polinómio, o modelo tende a se tornar excessivamente sensível a pequenas variações nos dados, o que pode levar ao *overfitting* e, conseqüentemente, a um pior desempenho em dados de teste.

### 2.4.3. Modelos Múltiplos com *Feature Selection*




Figura 2.15.: *KNIME*: Modelos de *Machine Learning* múltiplos do *dataset* World Happiness Index and Inflation.

Para este workflow, foram utilizados quatro modelos distintos de *Linear Regression*, *Polynomial Regression*, *Random Forest* e *Multi Layer Perceptron*, — com o objetivo de identificar quais modelos apresentariam melhor desempenho em um cenário de preparação genérica dos dados.

Começou-se por efetuar a seguinte preparação de dados:

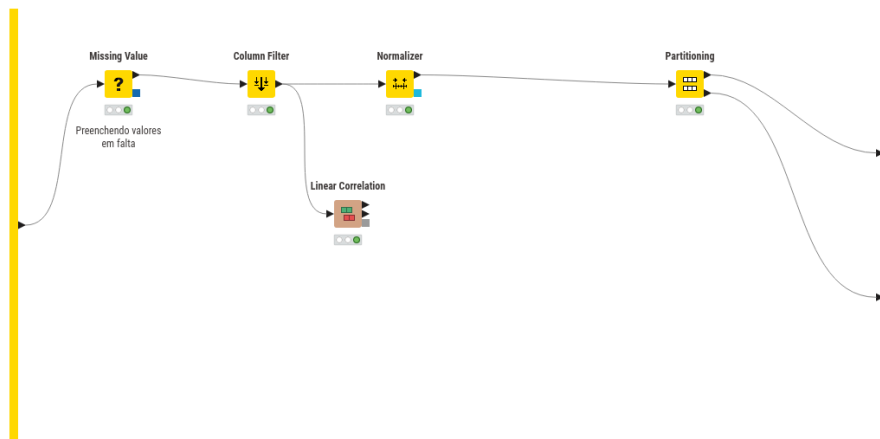


Figura 2.16.: *KNIME*: Preparação de dados do modelo de *Machine Learning* múltiplo do *dataset* World Happiness Index and Inflation.

Após a aplicação dos nodos de *Machine Learning*, foram obtidos os seguintes resultados:

| RowID | R <sup>2</sup><br>Number (double) | mean absolute error<br>Number (double) | Model<br>String   |
|-------|-----------------------------------|----------------------------------------|-------------------|
| Row0  | 0.794                             | 0.067                                  | Linear Regression |
| Row1  | 0.739                             | 0.075                                  | Polynomial        |
| Row2  | 0.824                             | 0.062                                  | Random Forest     |
| Row3  | 0.675                             | 0.085                                  | RProp MLP         |

Figura 2.17.: *KNIME*: Resultados do modelo de *Machine Learning* múltiplo do *dataset* World Happiness Index and Inflation.

Como podemos constatar na imagem, o modelo de *Random Forest* obteve os melhores resultados, seguido do modelo de *Linear Regression*.

#### 2.4.4. Modelos Múltiplos com *Binning*



Figura 2.18.: *KNIME*: Modelos de *Machine Learning* múltiplos do *dataset* World Happiness Index and Inflation - *Binning*.

Neste modelo, foram utilizados três modelos de *Machine Learning* diferentes - *Linear Regression*, *Polynomial Regression* e *Random Forest*. Começou-se por efetuar a seguinte preparação de dados:




Figura 2.19.: *KNIME*: Preparação de dados do modelo de *Machine Learning* múltiplo do *dataset* World Happiness Index and Inflation - *Binning*.

Começamos por aplicar um tratamento para *Missing Values*, utilizando a abordagem que anteriormente apresentou os melhores resultados. Em seguida, realizamos a normalização dos dados, o que é especialmente útil para algoritmos sensíveis à escala das variáveis, como a regressão linear e redes neurais, garantindo que todas as variáveis contribuam igualmente para o modelo.

Por fim, adicionamos um nodo de *Auto-Binner*, que transforma variáveis contínuas em categorias discretas. Essa transformação pode ser vantajosa para algoritmos baseados em árvores, como o *Random Forest*, pois facilita a identificação de padrões e a segmentação dos dados de forma mais eficiente. Assim, cada etapa do processo contribuiu para a melhoria da qualidade dos dados e, conseqüentemente, para o desempenho dos modelos.

Após a aplicação dos nodos de *Machine Learning*, foram obtidos os seguintes resultados:

| RowID | R^2<br>Number (double) | mean absolute error<br>Number (double) | Model<br>String   |
|-------|------------------------|----------------------------------------|-------------------|
| Row0  | 0.807                  | 0.064                                  | Linear Regression |
| Row1  | 0.75                   | 0.074                                  | Polynomial        |
| Row2  | 0.789                  | 0.069                                  | Random Forest     |

Figura 2.20.: *KNIME*: Resultados do modelo de *Machine Learning* múltiplo do *dataset* World Happiness Index and Inflation - *Binning*.

O modelo de *Linear Regression* obteve os melhores resultados, seguido do modelo de *Random Forest*.

### 2.4.5. MLP - Multi-Layer Perceptron




Figura 2.21.: KNIME: Modelo de MLP do dataset World Happiness Index and Inflation.

Neste modelo, iniciou-se o processo com a preparação dos dados, que incluiu o tratamento de *outliers* e *Missing Values*, seguido da normalização das variáveis. Essas etapas são essenciais para garantir que o modelo receba dados consistentes, reduzindo o impacto de valores extremos e evitando viés causado por dados ausentes. A normalização, por sua vez, é particularmente importante para algoritmos como o *Multi-Layer Perceptron* (MLP), que são sensíveis à escala dos dados, permitindo uma convergência mais eficiente durante o treinamento.

Adicionalmente, aplicamos dois tipos de partição: *hold-out validation*, que permite uma avaliação rápida do desempenho com base numa divisão fixa entre treino e teste, e *cross-validation*, que oferece uma estimativa mais robusta e generalizável ao avaliar o modelo em diferentes subconjuntos do conjunto de dados. Essa abordagem combinada contribui para uma avaliação mais confiável da performance do modelo MLP em diferentes contextos.

Após a aplicação dos nodos de MLP, foram obtidos os seguintes resultados:

| RowID | R <sup>2</sup><br>Number (double) | mean absolute error<br>Number (double) | Partition<br>String |
|-------|-----------------------------------|----------------------------------------|---------------------|
| Row0  | 0.758                             | 0.081                                  | 70% - 20%           |
| Row1  | 0.769                             | 0.077                                  | X-Partition         |

Figura 2.22.: KNIME: Resultados do modelo de MLP do dataset World Happiness Index and Inflation.

## 2.5. Análise dos Modelos

Na tabela seguinte, são apresentados, em sumário, os resultados obtidos para cada um dos modelos de *Machine Learning* utilizados, com as respetivas *accuracies*.

| <b>Modelo</b>                | <b>Tratamento</b>                                             | <b>Resultado</b>      |
|------------------------------|---------------------------------------------------------------|-----------------------|
| <i>Random Forest</i>         | Removendo Missing Values                                      | 82%                   |
| <i>Random Forest</i>         | Alterando missing values pelo valor mais frequente            | 82.6%                 |
| <i>Random Forest</i>         | Alterando missing values pela média dos valores mais próximos | 82.5%                 |
| <i>Polynomial Regression</i> | Desenvolvendo modelo de treino com Grau 01                    | 74.8%                 |
| <i>Polynomial Regression</i> | Desenvolvendo modelo de treino com Grau 02                    | 34.9%                 |
| <i>Polynomial Regression</i> | Desenvolvendo modelo de treino com Grau 03                    | -293.6 R <sup>2</sup> |
| <i>Linear Regression</i>     | Normalização de dados                                         | 73.9%                 |
| <i>Polynomial Regression</i> | Normalização de dados                                         | 73.9%                 |
| <i>Random Forest</i>         | Normalização de dados                                         | 82.4%                 |
| <i>MLP</i>                   | Normalização de dados                                         | 67.5%                 |
| <i>Linear Regression</i>     | Binning e Normalização de dados                               | 80.7%                 |
| <i>Polynomial Regression</i> | Binning e Normalização de dados                               | 75%                   |
| <i>Random Forest</i>         | Binning e Normalização de dados                               | 78.9%                 |
| <i>MLP</i>                   | Removendo outliers                                            | 75.8%                 |
| <i>Random Forest</i>         | Removendo outliers e cross-validation                         | 76.7%                 |

Tabela 2.1.: Resultados dos modelos de *Machine Learning* do *dataset Loan*

É possível observar que o modelo de *Random Forest* com atualização de *missing values* obteve os melhores resultados, enquanto que o modelo polinomial de grau 03 e 02 obtiveram os piores. Acreditamos que isto se deve ao facto de o modelo de *Random Forest*, como mencionado na análise do primeiro *dataset*, ser mais robusto, tolerante a dados imperfeitos e eficaz ao lidar com variáveis categóricas e não linearidades sem necessidade de normalização ou transformação extensiva dos dados. Por outro lado, a regressão polinomial, especialmente em graus mais altos, tende a sofrer com *overfitting* e sensibilidade a *outliers*, o que compromete fortemente a sua capacidade preditiva, como evidenciado pelo R<sup>2</sup> negativo.

### 3. Conclusão

Em suma, o presente trabalho teve como objetivo explorar e analisar dois *datasets* distintos, aplicando técnicas de *Machine Learning* para prever o estado de um empréstimo e o índice de felicidade mundial. O primeiro *dataset* foi o *Loan Dataset*, que contém dados sobre empréstimos e os seus estados, enquanto o segundo foi o *World Happiness Index and Inflation Dataset*, que contém dados sobre o índice de felicidade mundial e a inflação em diversos países.

Através da análise de dados mais categóricos no primeiro *dataset*, foi possível observar que o modelo de *Random Forest* com *feature selection* obteve os melhores resultados, enquanto que o modelo de *Clustering* obteve os piores resultados.

No segundo *dataset*, a análise de dados mais numéricos revelou que o modelo de *Random Forest* também obteve os melhores resultados, enquanto que o modelo de *Polynomial Regression* de grau 3 obteve os piores resultados.

Através da análise dos resultados, foi possível concluir que o modelo de *Random Forest* é o mais robusto e eficaz para lidar tanto com dados categóricos como numéricos.

Além disso, a utilização de técnicas de pré-processamento, como a normalização e o tratamento de *missing values*, mostrou-se fundamental para melhorar o desempenho dos modelos. A normalização, em particular, é uma etapa crucial para algoritmos sensíveis à escala dos dados, como a regressão linear e redes neurais, enquanto o tratamento de *missing values* e *outliers* é essencial para garantir a integridade dos dados e evitar viés nos resultados.

# A. Apêndices

## A.1. Apêndice A: *KNIME* - Loan Dataset

Scorer View

Confusion Matrix

|                   | Approved (Predicted) | Pending (Predicted) | Rejected (Predicted) |        |
|-------------------|----------------------|---------------------|----------------------|--------|
| Approved (Actual) | 821                  | 391                 | 208                  | 57.82% |
| Pending (Actual)  | 364                  | 961                 | 1453                 | 34.59% |
| Rejected (Actual) | 191                  | 1441                | 2750                 | 62.76% |
|                   | 59.67%               | 34.41%              | 62.34%               |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 52.82%           | 47.18%        | 0.221                      | 4532                 | 4048                   |

Figura A.1.: *KNIME*: *Confusion Matrix* do modelo de *Decision Tree* com *hold-out validation* do dataset Loan.

Scorer View

Confusion Matrix

|                   | Approved (Predicted) | Pending (Predicted) | Rejected (Predicted) |        |
|-------------------|----------------------|---------------------|----------------------|--------|
| Approved (Actual) | 4067                 | 2000                | 1067                 | 57.01% |
| Pending (Actual)  | 1857                 | 4809                | 7652                 | 33.59% |
| Rejected (Actual) | 945                  | 7513                | 13019                | 60.62% |
|                   | 59.21%               | 33.58%              | 59.89%               |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 51.00%           | 49.00%        | 0.195                      | 21895                | 21034                  |

Figura A.2.: *KNIME*: *Confusion Matrix* do modelo de *Decision Tree* com *cross validation* do dataset Loan.



## Scorer View

Confusion Matrix

|            | 0 (Predicted) | 1 (Predicted) |        |
|------------|---------------|---------------|--------|
| 0 (Actual) | 7130          | 68            | 99.06% |
| 1 (Actual) | 1258          | 166           | 11.66% |
|            | 85.00%        | 70.94%        |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 84.62%           | 15.38%        | 0.161                      | 7296                 | 1326                   |

Figura A.3.: *KNIME: Confusion Matrix* do modelo de *Linear Regression* com *hold-out validation* do dataset Loan.

## Scorer View

Confusion Matrix

|            | 0 (Predicted) | 1 (Predicted) |        |
|------------|---------------|---------------|--------|
| 0 (Actual) | 35587         | 352           | 99.02% |
| 1 (Actual) | 6330          | 841           | 11.73% |
|            | 84.90%        | 70.49%        |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 84.50%           | 15.50%        | 0.161                      | 36428                | 6682                   |

Figura A.4.: *KNIME: Confusion Matrix* do modelo de *Linear Regression* com *cross validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 311                  | 1113                         | 21.84% |
| Rejected/Pending (Actual) | 204                  | 6994                         | 97.17% |
|                           | 60.39%               | 86.27%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 84.73%           | 15.27%        | 0.255                      | 7305                 | 1317                   |

Figura A.5.: *KNIME: Confusion Matrix* do modelo de *Logistic Regression* com *hold-out validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 1563                 | 5608                         | 21.80% |
| Rejected/Pending (Actual) | 1014                 | 34925                        | 97.18% |
|                           | 60.65%               | 86.16%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 84.64%           | 15.36%        | 0.255                      | 36488                | 6622                   |

Figura A.6.: *KNIME: Confusion Matrix* do modelo de *Logistic Regression* com *cross validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 519                  | 905                          | 36.45% |
| Rejected/Pending (Actual) | 2158                 | 5040                         | 70.02% |
|                           | 19.39%               | 84.78%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 64.47%           | 35.53%        | 0.048                      | 5559                 | 3063                   |

Figura A.7.: *KNIME: Confusion Matrix* do modelo de *Clustering* com *hold-out validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 3001                 | 4170                         | 41.85% |
| Rejected/Pending (Actual) | 13779                | 22160                        | 61.66% |
|                           | 17.88%               | 84.16%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 58.36%           | 41.64%        | 0.023                      | 25161                | 17949                  |

Figura A.8.: *KNIME: Confusion Matrix* do modelo de *Clustering* com *cross validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 461                  | 963                          | 32.37% |
| Rejected/Pending (Actual) | 333                  | 6865                         | 95.37% |
|                           | 58.06%               | 87.70%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 84.97%           | 15.03%        | 0.337                      | 7326                 | 1296                   |

Figura A.9.: *KNIME: Confusion Matrix* do modelo de *Decision Tree* com *feature selection* e *hold-out validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 2204                 | 4967                         | 30.73% |
| Rejected/Pending (Actual) | 1427                 | 34512                        | 96.03% |
|                           | 60.70%               | 87.42%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 85.17%           | 14.83%        | 0.334                      | 36716                | 6394                   |

Figura A.10.: *KNIME: Confusion Matrix* do modelo de *Decision Tree* com *feature selection* e *cross validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 386                  | 1038                         | 27.11% |
| Rejected/Pending (Actual) | 262                  | 6936                         | 96.36% |
|                           | 59.57%               | 86.98%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 84.92%           | 15.08%        | 0.300                      | 7322                 | 1300                   |

Figura A.11.: *KNIME: Confusion Matrix* do modelo de *MLP* com *hold-out validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 1722                 | 5449                         | 24.01% |
| Rejected/Pending (Actual) | 1123                 | 34816                        | 96.88% |
|                           | 60.53%               | 86.47%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 84.76%           | 15.24%        | 0.275                      | 36538                | 6572                   |

Figura A.12.: *KNIME: Confusion Matrix* do modelo de *MLP* com *cross validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 854                  | 570                          | 59.97% |
| Rejected/Pending (Actual) | 470                  | 6728                         | 93.47% |
|                           | 64.50%               | 92.19%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 87.94%           | 12.06%        | 0.550                      | 7582                 | 1040                   |

Figura A.13.: *KNIME: Confusion Matrix* do modelo de *Backwards Feature Selection* com *hold-out validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 4257                 | 2914                         | 59.36% |
| Rejected/Pending (Actual) | 2417                 | 33522                        | 93.27% |
|                           | 63.78%               | 92.00%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 87.63%           | 12.37%        | 0.541                      | 37779                | 5331                   |

Figura A.14.: *KNIME: Confusion Matrix* do modelo de *Backwards Feature Selection* com *cross validation* do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 854                  | 570                          | 59.97% |
| Rejected/Pending (Actual) | 470                  | 6728                         | 93.47% |
|                           | 64.50%               | 92.19%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 87.94%           | 12.06%        | 0.550                      | 7582                 | 1040                   |

Figura A.15.: *KNIME*: Confusion Matrix do modelo de Forward Feature Selection com hold-out validation do dataset Loan.

## Scorer View

Confusion Matrix

|                           | Approved (Predicted) | Rejected/Pending (Predicted) |        |
|---------------------------|----------------------|------------------------------|--------|
| Approved (Actual)         | 4257                 | 2914                         | 59.36% |
| Rejected/Pending (Actual) | 2417                 | 33522                        | 93.27% |
|                           | 63.78%               | 92.00%                       |        |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 87.63%           | 12.37%        | 0.541                      | 37779                | 5331                   |

Figura A.16.: *KNIME*: Confusion Matrix do modelo de Forward Feature Selection com cross validation do dataset Loan.

## A.2. Apêndice B: *KNIME* - Happiness and Inflation Dataset

| Statistics - 3:223:220:203 ...        | Statistics - 3:223:220:209 ...        | Statistics - 3:223:220:215 ...        |
|---------------------------------------|---------------------------------------|---------------------------------------|
| File                                  | File                                  | File                                  |
| R <sup>2</sup> : 0.82                 | R <sup>2</sup> : 0.826                | R <sup>2</sup> : 0.825                |
| Mean absolute error: 0.308            | Mean absolute error: 0.365            | Mean absolute error: 0.37             |
| Mean squared error: 0.176             | Mean squared error: 0.236             | Mean squared error: 0.237             |
| Root mean squared error: 0.419        | Root mean squared error: 0.485        | Root mean squared error: 0.487        |
| Mean signed difference: 0.06          | Mean signed difference: -0.018        | Mean signed difference: -0.025        |
| Mean absolute percentage error: 0.056 | Mean absolute percentage error: 0.076 | Mean absolute percentage error: 0.077 |
| Adjusted R <sup>2</sup> : 0.82        | Adjusted R <sup>2</sup> : 0.826       | Adjusted R <sup>2</sup> : 0.825       |

Figura A.17.: *KNIME*: Scorer do modelo de Random Forest do dataset World Happiness Index and Inflation.

| Statistics - 3:223:219:203 -... |        | Statistics - 3:223:219:209 -... |        | Statistics - 3:223:219:215 - N... |          |
|---------------------------------|--------|---------------------------------|--------|-----------------------------------|----------|
| File                            |        | File                            |        | File                              |          |
| R <sup>2</sup> :                | 0.748  | R <sup>2</sup> :                | 0.349  | R <sup>2</sup> :                  | -293.602 |
| Mean absolute error:            | 0.441  | Mean absolute error:            | 0.476  | Mean absolute error:              | 1.464    |
| Mean squared error:             | 0.331  | Mean squared error:             | 0.857  | Mean squared error:               | 387.426  |
| Root mean squared error:        | 0.576  | Root mean squared error:        | 0.926  | Root mean squared error:          | 19.683   |
| Mean signed difference:         | -0.038 | Mean signed difference:         | -0.001 | Mean signed difference:           | 0.997    |
| Mean absolute percentage error: | 0.089  | Mean absolute percentage error: | 0.099  | Mean absolute percentage error:   | 0.409    |
| Adjusted R <sup>2</sup> :       | 0.748  | Adjusted R <sup>2</sup> :       | 0.349  | Adjusted R <sup>2</sup> :         | -293.602 |

Figura A.18.: *KNIME: Scorer* do modelo de *Polynomial Regression* do dataset World Happiness Index and Inflation.

| Statistics - 3:223:221:203 -... |        | Statistics - 3:223:221:209 -... |        | Statistics - 3:223:221:218 -... |        | Statistics - 3:223:221:222 -... |        |
|---------------------------------|--------|---------------------------------|--------|---------------------------------|--------|---------------------------------|--------|
| File                            |        | File                            |        | File                            |        | File                            |        |
| R <sup>2</sup> :                | 0.794  | R <sup>2</sup> :                | 0.739  | R <sup>2</sup> :                | 0.824  | R <sup>2</sup> :                | 0.675  |
| Mean absolute error:            | 0.067  | Mean absolute error:            | 0.075  | Mean absolute error:            | 0.062  | Mean absolute error:            | 0.085  |
| Mean squared error:             | 0.008  | Mean squared error:             | 0.01   | Mean squared error:             | 0.007  | Mean squared error:             | 0.012  |
| Root mean squared error:        | 0.088  | Root mean squared error:        | 0.099  | Root mean squared error:        | 0.082  | Root mean squared error:        | 0.111  |
| Mean signed difference:         | -0.006 | Mean signed difference:         | -0.004 | Mean signed difference:         | -0.004 | Mean signed difference:         | -0.006 |
| Mean absolute percentage error: | 0.149  | Mean absolute percentage error: | 0.163  | Mean absolute percentage error: | 0.141  | Mean absolute percentage error: | 0.192  |
| Adjusted R <sup>2</sup> :       | 0.794  | Adjusted R <sup>2</sup> :       | 0.739  | Adjusted R <sup>2</sup> :       | 0.824  | Adjusted R <sup>2</sup> :       | 0.675  |

Figura A.19.: *KNIME: Scorer* do modelo de *Machine Learning* múltiplo do dataset World Happiness Index and Inflation.

| Statistics - 3:223:222:203 -... |        | Statistics - 3:223:222:209 -... |        | Statistics - 3:223:222:218 ...  |       |
|---------------------------------|--------|---------------------------------|--------|---------------------------------|-------|
| File                            |        | File                            |        | File                            |       |
| R <sup>2</sup> :                | 0.807  | R <sup>2</sup> :                | 0.75   | R <sup>2</sup> :                | 0.789 |
| Mean absolute error:            | 0.064  | Mean absolute error:            | 0.074  | Mean absolute error:            | 0.069 |
| Mean squared error:             | 0.007  | Mean squared error:             | 0.009  | Mean squared error:             | 0.008 |
| Root mean squared error:        | 0.085  | Root mean squared error:        | 0.097  | Root mean squared error:        | 0.089 |
| Mean signed difference:         | -0.006 | Mean signed difference:         | -0.005 | Mean signed difference:         | 0.004 |
| Mean absolute percentage error: | 0.139  | Mean absolute percentage error: | 0.161  | Mean absolute percentage error: | 0.167 |
| Adjusted R <sup>2</sup> :       | 0.807  | Adjusted R <sup>2</sup> :       | 0.75   | Adjusted R <sup>2</sup> :       | 0.789 |

Figura A.20.: *KNIME: Scorer* do modelo de *Machine Learning* múltiplo do dataset World Happiness Index and Inflation - *Binning*.

| Statistics - 3:223:223:203 -...          |        | Statistics - 3:223:223:209 ...           |       |
|------------------------------------------|--------|------------------------------------------|-------|
| File                                     |        | File                                     |       |
| ⚠ Can't calculate Mean Absolute Perce... |        | ⚠ Can't calculate Mean Absolute Perce... |       |
| R <sup>2</sup> :                         | 0.758  | R <sup>2</sup> :                         | 0.769 |
| Mean absolute error:                     | 0.081  | Mean absolute error:                     | 0.077 |
| Mean squared error:                      | 0.011  | Mean squared error:                      | 0.01  |
| Root mean squared error:                 | 0.105  | Root mean squared error:                 | 0.1   |
| Mean signed difference:                  | -0.003 | Mean signed difference:                  | 0.001 |
| Mean absolute percentage error:          | NaN    | Mean absolute percentage error:          | NaN   |
| Adjusted R <sup>2</sup> :                | 0.758  | Adjusted R <sup>2</sup> :                | 0.769 |

Figura A.21.: *KNIME: Scorer* do modelo de *MLP* do dataset World Happiness Index and Inflation.

# Referências

- [1] KNIME, *KNIME Analytics Platform*, <https://www.knime.com/>.
- [2] *World Happiness Index and Inflation Dataset*, <https://www.kaggle.com/datasets/agrafintech/world-happiness-index-and-inflation-dataset>.